

베이지스 튜터링 1주차

Introduction + Conjugate Families

Jaewoo Shin

Sep 14 2024

Contents

- Seminar OT
- R and RMarkdown Basics
- Introduction to Bayesian Statistics (베이지스 통계)
- Conjugate Families

Orientation

현재 세미나의 계획이며, 향후 변동될 수도 있습니다.

- Week 1 - OT, R + RMarkdown Basics, Introduction to 통계전산 + 베이지 통계
- Week 2 - Markov Chain, Monte Carlo
- Week 3 - MCMC (Markov Chain Monte Carlo), MH-Algorithm + 직접 구현
- Week 4 - Conjugate Priors, GLM, Bayesian Regression
- Week 5 - Bayesian Hierarchical Regression, Gibbs Sampler
- Week 6 - Bayesian Model Comparison, Bayesian Non-Parametrics
- Week 7 - Preliminary Week

해당 세미나에서는 **R** 만 사용할 예정이며, 제가 드리는 과제는 실제 수업에서의 과제도 포함이 되어 있습니다.

Assignments

- 과제는 필수가 전혀 아닙니다, 하지만 과제를 풀어서 저에게 제출하시면 제가 살피어서 코멘트를 해드리도록 하겠습니다.
- 과제는 실제 강의에서 나오는 이전 과제들이 나오는 경우도 있기에 푸시는 것을 추천합니다.
- 여러 문제들이 나오는 경우도 있을 것이며, 해당 문제가 통계전산에 더 유용한지, 혹은 베イズ 통계에 더 유용한지에 대해서도 첨부를 하도록 하겠습니다.

R Basics

왜 굳이 **R** 를 고집하는걸까요?

- R 은 통계학자들을 위해 만들어진 언어인 만큼 다양한 통계분석 기능들을 제공해줍니다. 이것을 활용해서 더 편하게 코드를 짤 수가 있습니다.
- DataFrame, Matrix 와 같은 형태의 데이터를 유저가 Numpy 에 비해서 더 편하게 다룰 수가 있습니다.
- Environment (환경) 을 볼 수 있기에 본인이 저장해둔 변수들을 실시간으로 볼 수 있는 편리함이 있습니다. 일회용으로 과제를 하기에는 아주 용이합니다.

당연히 이것은 오로지 **분석** 이라는 용도로서의 장점들이며, 실제로 프로그램을 짤 때는 다른 언어를 사용하는 것이 효율적이긴 하나, 해당 강의들을 수강하기 위해서는 **R** 에 대한 지식도 충분합니다.

다만 베이지스 통계 에서는 **C++** 를 요구할 수도 있으니 이점 유의해주시길 바랍니다.

R Basics

그럼 과제를 풀기 위해서 **R**에서는 무엇을 할줄 알아야할까요?

- Vector, Matrix
- Defining a Function
- for, while and if-else
- 확률분포와 관련된 함수들 (ex: rnorm, dgamma, pbinom, qchisq, etc)
- Plotting

R Basics (Vector, Matrix)

① Vector

- $\mathbf{X} \in \mathbb{R}^p$ 형태로 표현하며, 1차원 데이터로, $\mathbf{X}$ 는 여기에서 p 길이의 벡터가 됩니다.
- **R**에서는 주로 `c()` 함수를 사용하지만, 원하는 형태에 따라서 `seq()`, `rep()` 함수들을 활용할 수 있습니다.
- 빈 벡터를 만들어서 안에 채우는 형태로 알고리즘을 진행할 경우, `c()` 보다는 `rep(NA, ·)` 으로 진행하면 연산이 더 빠릅니다.

② Matrix

- 파이썬에서 `numpy` 의 `array` 와 굉장히 유사하며, 2-차원 데이터입니다.
- `matrix()` 함수를 이용해서 만들어지며, `DataFrame` 도 `Matrix` 형태로 바꿔줄 수가 있습니다.
- 벡터와는 다르게 함수 안에 벡터 형태로 자료값이 명시되어야 합니다.
- `nrow` 와 `ncol` 을 통해서 Output 으로 나오는 매트릭스의 차원을 조정할 수 있습니다.
- `dim()` 을 통해서 크기를 확인할 수 있습니다.
- `% * %` 를 통해서 매트릭스 곱셈, `solve()` 를 통해서 Inverse Matrix 들을 구할 수가 있습니다.

R Basics (Function, for, while, if-else)

③ Defining a Function

- `function(Input){코드}` 를 통해서 함수를 직접 지정할 수 있습니다.
- `return()` 을 통해서 함수에서 연산된 값을 함수의 결과값으로 밝힐 수 있습니다.
- 직접 함수를 그때그때 불러와서 사용하게 된다면 Computation Time 은 길어지지만 코드를 바라보는 시각에서는 가독성이 좋아지기에 장점과 단점이 있습니다.

④ for, while and if-else

- 파이썬에서 하는 연산과 똑같으나, 파이썬과는 다르게 { 괄호를 포함시켜서 해줘야 된다는 차이점이 존재합니다.
- for loop 의 경우 list 내에 있는 원소들을 모두 다 Repeat 시키며, 이것은 `1:iterations` 등으로 활용할 수 있습니다.
- while loop 의 경우 괄호 내의 조건이 만족되는 동안은 루프가 반복이 됩니다.
- if-else 조건문의 경우 파이썬 내의 if, elif, else 와 똑같은 역할이며 ifelse 이라는 함수를 통해서 **indicator** 함수도 사용이 가능합니다.

R Basics (확률분포 함수들)

⑤ 확률분포 함수들

- 분포의 이름 앞에 r, p, q, d 를 사용함으로써 각각 의미하는 것은 다음과 같습니다.
 - r : 해당 파라미터에서 랜덤으로 추출하는 것.
 - p : 해당 값의 CDF 값, 즉 확률값을 준다.
 - q : 해당 확률 값의 Quantile 값, 즉 Inverse CDF 를 준다.
 - d : 해당 값의 PDF 값을 준다.
- 통계전산의 경우 중간고사 기간 이전까지는 오로지 `runif(n, 0, 1)` 만을 이용해서 랜덤으로 추출해야 합니다. 즉 `rnorm()` 등은 아예 사용하지 못합니다.
- 분포는 상황에 맞게끔 사용하면 되며, 이에 대한 예시는 `unif`, `norm`, `binom`, `gamma` (Shape Scale 인지 Shape Rate 인지 유의할 것!), `invgamma` (별도의 패키지가 필요합니다! 어느 패키지인지에 따라서 파라미터가 달라지기에 유의해서 사용해주세요!)
- 정확하게 어떻게 사용하는지는 분포 이름 앞에 ? 를 붙이면 됩니다.
예: `?rbinom`

R Basics (Plotting)

6 Plotting (1)

- `plot` : X 값들과 Y 값들이 있으며 그저 이에 대한 Scatterplot 을 그리고 싶을 때 사용되는 함수. (벡터로도 입력이 가능하다!)
- `abline` : 직선을 겹쳐서 그리고 싶을 때 사용되는 함수.
 - `abline(a=1, b=2)` → $y = x + 2$ 직선.
 - `abline(h=0)` → $y = 0$ 직선.
 - `abline(v=1)` → $x = 0$ 직선.
- `hist` : 원소들의 히스토그램을 그려준다. 이것을 통해서 데이터가 어떤 분포의 모양을 가졌는지를 알 수가 있습니다.
 - `breaks` : 히스토그램 내에서 얼마나 썩이나 쪼갤 것인지
 - `freq` : y -축의 값을 $[0, 1]$ 사이로 바꿀지
- `density` : 플롯을 바로 그려주는 함수는 아니지만, 데이터를 받으면 그것을 밀도함수로 바꾸어주는 함수라고 생각하시면 됩니다.
 - 베イズ 과제에서는 `plot(density(값들))` 형태로 자주 사용됩니다.
 - 여기에서 **값들**에 해당하는 것은 베イズ에서는 MCMC 샘플들입니다.

R Basics (Plotting)

⑥ Plotting (2)

- pch : 점의 모양
- cex : 점의 크기
- col : 점/선 의 색깔
- lty : 선의 종류
- lwd : 선의 굵기
- xlim, ylim : c(a, b) 으로 입력하면 x/y 축이 a 와 b 사이로 가게 된다.
- xlab, ylab : x/y 축의 이름들
- main : Plot 자체의 이름
- legend : 객체들의 속성을 나타내준다
- par(mfrow=c(a, b)) : 여러 개의 Plot 들을 $a \times b$ 형태로 보여주고 싶을 때 사용하는 Option
- add = True : 기존 플롯 위에 그릴지 아닐지

R Markdown Basics

왜 굳이 **RMarkdown** 을 고집할까요?

- 두 강의 모두 보고서 형태의 과제가 굉장히 많습니다 (23-2 기준 통전 8개, 베이즈 6개).
- 보고서에는 그럼 어떤 코드를 써서 어떤 결과물을 썼는지와 이에 대한 해설까지 필요합니다.
- **RMD** 를 사용하면 보고서를 작성하는 것이 엄청 편해지며, 아래와 같은 엄청나게 복잡한 수식도 쉽게 적을 수가 있게 됩니다!

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{-\alpha-1} \exp\left(-\frac{\beta}{x}\right)$$

- 작성이 완료됐다면, Knit 버튼을 누르면 되며, Html, Word, pdf 문서를 얻을 수가 있습니다.
- 당연하게도 필수는 아니며, 다른 방법이 편하시면 그걸로 가시면 됩니다!

R Markdown Basics (Latex 1)

수식 작성하는데에 중요한 것들 :

- 모든 등식에는 \$ 기호 사이에 써야 합니다.
- 그리스문자, 혹은 자주 사용하는 기호들은 \뒤에 붙이면 됩니다.
예: σ : `\sigma`, $\exp$: `\exp`, $\sqrt{2}$: `\sqrt{2}`
- _ 와 ^ 는 각각 Sub-script, Super-script 를 의미합니다.
예: 2_a : `2_a`, b^X : `b^X`, A_c^b : `A^b_c`
- `\frac {}{} :` 분수를 의미합니다.
예: $\frac{1}{2}$: `\frac{1}{2}`
- $(\sim)$ 는 `\sim` 으로.
- $(\propto)$ 는 비례 기호, `\propto` 으로.

R Markdown Basics (Latex 2)

글자를 꾸미는 방법들 :

- `\textbf{}` : **Bold Text**
- `\textit{}` : *Italic Text*
- `\underline{}` : Underline
- `\texttt{}` : Code Text
- `\mathbf{}` : **X**, Bold Symbol
- `\mathbb{}` : $\mathbb{R}$, 특수 기호

자주 사용되는 기호들 :

- `\le`, `\ge`, `\neq` : 부등호들 ($\leq, \geq, \neq$)
- `\hat{}`, `\bar{}`, `\tilde{}` : 문자 위 꾸미기 $\hat{X}, \bar{X}, \tilde{X}$
- `\in`, `\cap`, `\cup` : 집합 기호들 $\in, \cap, \cup$
- `\infty` : 무한대 ∞
- `\rightarrow`, `\leftarrow`, `\leftrightarrow` : 화살표들 $\rightarrow, \leftarrow, \leftrightarrow$
- `\sum`, `\prod`, `\Sigma`, `\Pi` : $\sum, \prod, \Sigma, \Pi$

베이즈 통계 (수업 관련)

통계전산과는 다르게 패키지 사용이 가능하지만, 기본적으로 **R** 를 다 사용합니다.

이것은 더 **효율적으로** 코드가 돌아가게 만들기 위해서입니다.

- 베이즈는 기본적으로 파라미터 자체를 확률변수로 바라본다는 관점이 있습니다.
- 이를 통해서 Posterior $P(\theta | X)$ 를 구축하는 것이 가능합니다.
- 수식으로는 당연히 여러분들이 아시는 Bayes Theorem 입니다. 하지만 이것을 알고 있다고 해서 직접적으로 샘플링은 어떻게 할까요?
- 바로 **MCMC** 를 활용하는 것입니다.
- C++ 코드도 다뤄야 할 줄 알아야되지만, ChatGPT 의 도움을 받으면 수월해집니다.

베이지 통계 (Frequentist vs Bayesian)

Frequentist :

- 확률들을 Long-run frequencies (같은 사건을 굉장히 반복했을 때 사건이 일어나는 비율) 으로 인식합니다.
- 확률변수 $\mathbf{X}$ 가 있다면, 이것과 관련된 모수인 θ 를 Fixed Parameter, Constant 으로 인식합니다.
- 목표 : 빈도의 보장을 갖는 방법론들을 만드는 것

Bayesian :

- 확률을 주관적인 Degree of Belief (Prior) 으로 정의합니다.
- 확률변수 $\mathbf{X}$ 가 있다면, 이것과 관련된 모수 (Parameter) 인 θ 를 확률변수, 그것의 모수 (Hyperparameter) 도 확률변수 으로 인식합니다.
- 목표 : 주관적인 신념을 토대로 분석하는 것

베이즈 통계 (Bayes Theorem 1)

베이즈 정리는 다음과 같습니다.

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)}, \quad P(B) \neq 0$$

- $P(A | B) P(B | A)$: 조건부 확률들
- $P(A), P(B)$: Marginal 확률들

베이즈 통계는 이 정리를 통해서 만들어졌습니다.

이 정리를 정확하게 살피면, 다음과 같이 적을 수 있습니다.

$$P(B | A) = \frac{P(A \cap B)}{P(A)}, \quad P(A \cap B) = P(B | A) \cdot P(A)$$

베イズ 통계 (Bayes Theorem 2)

그럼 베イズ 정리를 P 말고 다르게 표현을 하겠습니다.

$$\pi(\boldsymbol{\theta} \mid \mathbf{X}) = \frac{f(\mathbf{X} \mid \boldsymbol{\theta})p(\boldsymbol{\theta})}{\int f(\mathbf{X} \mid \boldsymbol{\theta})p(\boldsymbol{\theta})d\boldsymbol{\theta}}$$

- $\pi(\boldsymbol{\theta} \mid \mathbf{X})$: Posterior Density (저희가 궁극적으로 궁금한 것!)
- $f(\mathbf{X} \mid \boldsymbol{\theta})$: Likelihood
- $p(\boldsymbol{\theta})$: Prior (저희의 주관적인 믿음)
- $\int f(\mathbf{X} \mid \boldsymbol{\theta})p(\boldsymbol{\theta})d\boldsymbol{\theta}$: Normalizing Constant

자세히 보면, 분모는 $\boldsymbol{\theta}$ 에 의존하고 있지 않습니다. 그렇기 때문에 저희는 다음과 같이 적을 수 있게 됩니다.

$$\pi(\boldsymbol{\theta} \mid \mathbf{X}) \propto f(\mathbf{X} \mid \boldsymbol{\theta})p(\boldsymbol{\theta})$$

이렇게 Proportional to 한 값들의 가장 심플한 것을 **Kernel** 이라고 부릅니다. 그럼 마지막 식은 Posterior 의 Kernel 이라고 부를 수 있습니다.

예시 문제 (1)

1000 개의 제품들 중에서 145 개 만이 불량이라고 생각하겠으며, 불량일 확률은 베타 분포를 따른다는 Prior 를 가정하겠습니다. 그럼 이것을 다음과 같은 Hierarchical Model 을 구성할 수 있습니다.

$$\mathbf{X} \sim \text{Binom}(1000, \theta)$$

$$\theta \sim \text{Beta}(a, b)$$

- $f(\mathbf{X} \mid \theta) \propto \theta^{\mathbf{X}}(1 - \theta)^{1000 - \mathbf{X}}$
- $p(\theta) \propto \theta^{a-1} (1 - \theta)^{b-1}$
- $\pi(\theta \mid \mathbf{X}) \propto f(\mathbf{X} \mid \theta)p(\theta) = \theta^{a+\mathbf{X}-1} \cdot (1 - \theta)^{b+1000-\mathbf{X}-1}$

$$\propto \theta^{a+\mathbf{X}-1} \cdot (1 - \theta)^{b+1000-\mathbf{X}-1} \cdot \frac{\Gamma(a + \mathbf{X} + b + 1000 - \mathbf{X})}{\Gamma(a + \mathbf{X}) \cdot \Gamma(b + 1000 - \mathbf{X})}$$

$$\sim \text{Beta}(a + \mathbf{X}, b + 1000 - \mathbf{X})$$

예시 문제 (2)

그럼 저희는 Posterior 의 분포를 다음과 같이 정리할 수 있습니다.

$$\theta \mid \mathbf{X} \sim \text{Beta}(a + \mathbf{X}, b + 1000 - \mathbf{X})$$

1000 개 중에서 145 개 가 불량이기에 $\mathbf{X} = 145$ 으로 둘 수 있으며 Beta 분포의 평균을 이용할 수 있습니다.

$$E[\theta \mid \mathbf{X}] = \frac{a + \mathbf{X}}{a + b + 1000}$$

그러면 a 와 b 값들을 어떻게 설정하느냐에 따라서 이 값도 달라지게 됩니다.

베イズ 통계 (Confidence Interval vs Credible Interval)

Confidence Interval :

- 고정된 모수이며 구간이 움직입니다. 즉 신뢰구간 95% 는 100 개의 구간들 중에서 모수를 95 개가 포함한다는 의미입니다.
- $$P\left(\bar{X} - 1.96 \frac{S}{\sqrt{n}} \leq \mu \leq \bar{X} + 1.96 \frac{S}{\sqrt{n}}\right)$$

Credible Interval :

- 베イズ에서 사용되는 신뢰구간이며, 모수가 확률변수이기에 모수의 값 역시 변할 수도 있습니다.
- 95% Credible Interval 는 모수가 해당 구간 안에 위치할 확률이 0.95 이라는 뜻입니다.
- 다르게 말해, 구간이 $[a, b]$ 이면 $P(\theta \in [a, b] | X) = 0.95$ 이라는 의미입니다.
- $$P\left(\bar{x} - 1.96 \frac{s}{\sqrt{n}} \leq \mu \leq \bar{x} + 1.96 \frac{s}{\sqrt{n}}\right)$$

where $\bar{X} = \bar{x}$ and $S = s$ are observed data.

베イズ 통계 (HPD Interval 1)

Symmetric 과 HPD Interval 는 둘다 $P(a < \theta < b | X) = 0.95$ 를 만족합니다. 하지만 어떻게 바라보냐에 따라서 다릅니다.

Symmetric Interval :


- Mean 을 기준으로 0.95 만큼의 Density 가 찰 때까지 x-축을 증가합니다.
- 그저 quantile 함수를 이용하면 간단하게 구할 수 있습니다.

Highest Posterior Density (HPD) Interval :


- 위를 기준으로 (가장 높은 Density 를 포함해야하기)에 구간을 0.95 가 찰 때까지 넓힙니다.
- 비대칭인 분포들을 기준으로 가장 높은 밀도를 가진 구간들이 어디에 있는지를 알 수 있게 됩니다. 비대칭인 분포들을 많이 다룰 예정이기에 HPD Interval 는 베이즈에서 많이 다루게 될 예정입니다.

만약에 분포가 Symmetric 하다면 Symmetric Interval 와 HPD Interval 는 똑같습니다.

베이지스 통계 (HPD Interval 2)



HPD and Sym Intervals.png



HPD and Sym Interval.png

베イズ 통계 (HPD Interval 3)

그럼 이 HPD Interval 는 어떻게 구할까요? 바로 coda 패키지를 사용하는 것입니다.

- `final = rnorm(100000, posterior_mean, sqrt(posterior_var))`
- Symmetric Density Interval
- `quantile(final, c(0.025, 0.975))`
- HPD Interval
- `library(coda)`
- `HPDinterval(mcmc(final), prob = 0.95)`

Output 이 각각 (7.757207, 11.156792) 와 (7.783376, 11.17874) 으로 미세한 차이가 존재합니다.

Recap on Bayesian Statistics

베이즈에 대한 Recap 을 하겠습니다.

Frequentist :

- 확률들을 Long-run frequencies (같은 사건을 굉장히 반복했을 때 사건이 일어나는 비율) 으로 인식합니다.
- 확률변수 $\mathbf{X}$ 가 있다면, 이것과 관련된 모수인 θ 를 Fixed Parameter, Constant 으로 인식합니다.
- 목표 : 빈도의 보장을 갖는 방법론들을 만드는 것

Bayesian :

- 확률을 주관적인 Degree of Belief (Prior) 으로 정의합니다.
- 확률변수 $\mathbf{X}$ 가 있다면, 이것과 관련된 모수 (Parameter) 인 θ 를 확률변수, 그것의 모수 (Hyperparameter) 도 확률변수 으로 인식합니다.
- 목표 : 주관적인 신념을 토대로 분석하는 것

Recap on Bayesian Statistics

모수 자체를 확률변수로 보기 때문에, 저희는 베이즈 정리를 통해서 Posterior Distribution 을 다음과 같이 정리할 수 있습니다.

$$\pi(\theta | \mathbf{X}) = \frac{f(\mathbf{X} | \theta)p(\theta)}{\int f(\mathbf{X} | \theta)p(\theta)d\theta} = \frac{f(\mathbf{X} | \theta)p(\theta)}{f(\mathbf{X})} \propto f(\mathbf{X} | \theta)p(\theta)$$

- $\pi(\theta | \mathbf{X})$: Posterior Density (저희가 궁극적으로 궁금한 것!)
- $f(\mathbf{X} | \theta)$: Likelihood
- $p(\theta)$: Prior (저희의 주관적인 믿음)
- $\int f(\mathbf{X} | \theta)p(\theta)d\theta$: Normalizing Constant
- $f(\mathbf{X} | \theta)p(\theta)$: Kernel of Posterior Denstiy

Proportional 에서 모든 함수는 θ 에 대한 함수입니다.

Recap on Bayesian Statistics (Prior)

$$\pi(\boldsymbol{\theta} \mid \mathbf{X}) \propto f(\mathbf{X} \mid \boldsymbol{\theta})p(\boldsymbol{\theta})$$

- 모수가 이제는 확률변수로 취급되기 때문에 θ 역시 확률분포를 가져야합니다.
- 그럼 Prior 설정은 어떻게 하면 좋을까요?
 - 연구자의 임의로 Prior 를 설정할 수 있습니다.
 - 모수의 성질에 알맞게 설정을 하는 것이 가장 좋습니다.
 - 예로 $\theta > 0$ 이라면, $\theta \sim \Gamma(a, b)$ 와 같이 0 이상에 있는 분포로 설정하는 것이 더 좋습니다.
 - 이것을 Likelihood 와 결합하면 Posterior 가 됩니다.
 - Prior 의 영향력을 최대한 줄이는 것이 베이지에서의 관건이며, 이를 **Non-informative Prior** 이라고 부르기도 합니다.

Recap on Bayesian Statistics (Likelihood)

$$\pi(\boldsymbol{\theta} \mid \mathbf{X}) \propto f(\mathbf{X} \mid \boldsymbol{\theta})p(\boldsymbol{\theta})$$

- $\mathbf{X}$ 에 대한 식으로 바라본다면 Joint Distribution 식입니다.
- $\boldsymbol{\theta}$ 에 대한 식으로 바라본다면 우도함수 입니다.
- 모수 값을 모를 때에 주어진 데이터를 넣었을 때 가장 알맞는 모수 값이 무엇인지에 대한 수치입니다.
- $f(\mathbf{X} \mid \boldsymbol{\theta})$ 가 아닌 $L(\boldsymbol{\theta} \mid \mathbf{X})$ 으로 표기할 때도 있습니다.
- 이 값을 최대화 시키는 $\boldsymbol{\theta}$ 추정량을 MLE 이라고 부릅니다.

Recap on Bayesian Statistics (MCMC)

$$\pi(\boldsymbol{\theta} \mid \mathbf{X}) \propto f(\mathbf{X} \mid \boldsymbol{\theta})p(\boldsymbol{\theta})$$

- 기존에는 분모 부분이 존재를 하며, 그것을 저희는 Normalizing Constant 이라고 부르며, pdf 형태로 맞추기 위해서 존재합니다.
- 하지만 MCMC 의 경우에는 위와 같은 Un-normalized Density 에도 사용이 가능합니다.
- 베イズ에서 Posterior 를 구하기 위한 다른 기법을 사용하려면 반드시 Normalizing Constant 를 구해야되지만, 이것을 MCMC 의 경우 안 구해도 되기에 굉장히 유용하다고 할 수 있습니다.

Conjugate Prior

Posterior 와 Prior 가 똑같은 Family of Distribution 을 따라간다면, 그것을 저희는 Conjugate Prior 이라고 부릅니다.

즉 Posterior 과 Prior 분포 둘다 정규분포를 따르게 된다면 이것을 Conjugate Prior 라고 둘 수가 있는 것입니다.

- Likelihood 와 Prior 둘다 확률분포이기에 곱하는 것은 굉장히 복잡한 값이지만, 잘 알려진 케이스의 경우 이전 케이스를 갖다 사용하면 됩니다.
- Conjugate Prior 도 그 예시 중 하나이며, Likelihood 와 Prior 가 어떠한 분포를 따른다는 것을 이미 알고 있다면 Posterior 가 어떤 형태일지 아는 경우가 포함되어 있습니다.

Conjugate Prior (Examples)

- 기본적으로 Likelihood 는 데이터에 따라서 다르기에 저희가 임의로 고르지 못합니다.
- 하지만 Prior 의 경우 저희가 마음대로 고를 수 있기에 Likelihood 와 어울리는 형태로 만들어서 Posterior 분포를 Conjugate Prior 를 이용해서 구할 수 있게 됩니다.

Likelihood	Prior	Posterior	Parameter
Binomial	Beta	Beta	$B(n, \mathbf{p})$
Poisson	Gamma	Gamma	$\text{Pois}(\lambda)$
Normal	Inverse-Gamma	Inverse-Gamma	$N(\mu, \theta)$
Normal	Normal	Normal	$N(\theta, \sigma^2)$

Conjugate Prior for Normal Mean

필요한 것들 :

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left(-\frac{(x - \theta)^2}{2\sigma^2}\right)$$

Formulating the Posterior

베이즈 정리를 다시 갖고오자면, 다음과 같습니다.

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)}$$

이것을 이용해서 저희는 Posterior 를 구축하는 것이 가능하며, Conjugate Prior 이외의 예시에서도 보여드리겠습니다. (1주차 때 했던 겁니다)
1000 개의 제품들 중에서 145 개 만이 불량이라고 생각하겠으며, 불량일 확률은 베타 분포를 따른다는 Prior 를 가정하겠습니다. 그럼 이것을 다음과 같은 Hierarchical Model 을 구성할 수 있습니다.

Formulating the Posterior (Example 1)

$$\mathbf{X} \sim \text{Binom}(1000, \theta)$$

$$\theta \sim \text{Beta}(a, b)$$

- $f(\mathbf{X} \mid \theta) \propto \theta^{\mathbf{X}}(1 - \theta)^{1000 - \mathbf{X}}$
- $p(\theta) \propto \theta^{a-1}(1 - \theta)^{b-1}$
- $\pi(\theta \mid \mathbf{X}) \propto f(\mathbf{X} \mid \theta)p(\theta) = \theta^{a+\mathbf{X}-1} \cdot (1 - \theta)^{b+1000-\mathbf{X}-1}$

$$\propto \theta^{a+\mathbf{X}-1} \cdot (1 - \theta)^{b+1000-\mathbf{X}-1} \cdot \frac{\Gamma(a + \mathbf{X} + b + 1000 - \mathbf{X})}{\Gamma(a + \mathbf{X}) \cdot \Gamma(b + 1000 - \mathbf{X})}$$

$$\sim \text{Beta}(a + \mathbf{X}, b + 1000 - \mathbf{X})$$

Formulating the Posterior (Example 1)

그럼 저희는 Posterior 의 분포를 다음과 같이 정리할 수 있습니다.

$$\theta \mid \mathbf{X} \sim \text{Beta}(a + \mathbf{X}, b + 1000 - \mathbf{X})$$

1000 개 중에서 145 개 가 불량이기에 $\mathbf{X} = 145$ 으로 둘 수 있으며 Beta 분포의 평균을 이용할 수 있습니다.

$$E[\theta \mid \mathbf{X}] = \frac{a + \mathbf{X}}{a + b + 1000}$$

그러면 a 와 b 값들을 어떻게 설정하느냐에 따라서 이 값도 달라지게 됩니다.

Formulating the Posterior (Hierarchical Model))

이런 식으로 Likelihood 와 Prior 가 둘다 주어지게 된다면 Posterior 를 당연히 손쉽게 구할 수 있습니다.

Prior 역시 분포를 따르며, 그 분포에 있는 모수인 Hyperparameters a, b 역시 분포를 따른다고 봐야 합니다.

전체적인 틀을 짜서 Posterior 를 구축하게 되는 것을 Hierarchical Model 이라고 부릅니다. 즉

$$\mathbf{X} \sim \text{Binom}(1000, \theta)$$

$$\theta \sim \text{Beta}(a, b)$$

$$a \sim \Gamma(c, d), \quad b \sim \Gamma(e, f)$$

하지만 실제 상황에서는 Prior 를 이전 슬라이드와 같이 구체적으로 알 수 있는 상황은 굉장히 드물기에 데이터를 통해서 Prior 를 설정하는 경우가 자주 나옵니다. → Empirical Bayes!

Formulating the Posterior (Empirical Bayes)

저희 분포들을 다음과 같이 표현할 수 있습니다.

$$X \mid \theta \sim f(X \mid \theta)$$

$$\Theta \mid \gamma \sim h(\theta \mid \gamma)$$

γ 값 자체를 아예 데이터를 이용해서 추정을 해버리는 것!

$$g(x, \theta \mid \gamma) = f(x \mid \theta) \cdot h(\theta \mid \gamma)$$

$$m(x \mid \gamma) = \int_{-\infty}^{\infty} f(x \mid \theta) \cdot h(\theta \mid \gamma) d\theta = \int_{-\infty}^{\infty} g(x, \theta \mid \gamma) d\theta$$

그럼 $m(x \mid \gamma)$ 를 통해서 γ 를 추정할 수 있게 됩니다.
(보통은 MLE 를 사용합니다)

Formulating the Posterior (Example 2)

$$X_i \mid \lambda \sim \text{Pois}(\lambda), \quad i = 1, \dots, n$$

$$\Lambda \mid b \sim \text{Gamma}(1, b)$$

$$g(X \mid \lambda) = \frac{\lambda^{n \cdot \bar{x}}}{x_1! \cdots x_n!} \cdot e^{-n \cdot \lambda}, \quad \bar{x} = \frac{1}{n} \cdot \sum_{i=1}^n x_i$$

$$\begin{aligned} m(x \mid b) &= \int_0^\infty g(x \mid \lambda) \cdot h(\lambda \mid b) d\lambda \\ &= \int_0^\infty \frac{1}{x_1! \cdots x_n!} \cdot \lambda^{n \cdot \bar{x} + 1 - 1} \cdot e^{-n \cdot \lambda} \cdot \frac{1}{b} \cdot e^{-\lambda/b} \cdot d\lambda \\ &= \frac{\Gamma(n \cdot \bar{x} + 1) \cdot [b/(nb + 1)]^{n \cdot \bar{x} + 1}}{x_1! \cdots x_n!} \end{aligned}$$

$$\frac{\partial}{\partial b} \log(m(x \mid b)) = -\frac{1}{b} + (n \cdot \bar{x} + 1) \cdot \frac{1}{b \cdot (bn + 1)} \stackrel{\text{set}}{=} 0$$

=

Formulating the Posterior (Example 2)

$$\begin{aligned}\hat{b} = \bar{x}, \quad k(\lambda \mid x, \hat{b}) &\propto g(x, \lambda) \cdot h(\lambda \mid \hat{b}) \\ &\propto \lambda^{n \cdot \bar{x} + 1 - 1} \cdot e^{-\lambda \cdot [n + 1 / \hat{b}]} \sim \text{Gamma} \left(n \cdot \bar{x} + 1, \frac{\hat{b}}{n \cdot \hat{b} + 1} \right)\end{aligned}$$

$$\hat{\lambda} = [n \cdot \bar{x} + 1] \cdot \frac{\hat{b}}{n \cdot \hat{b} + 1} = (n \cdot \bar{x} + 1) \cdot \frac{\bar{x}}{n \cdot \bar{x} + 1} = \bar{x}$$

Empirical Bayes Estimator 는 MLE 와 똑같다!