

베이지스 튜터링 2주차

Jaewoo Shin

Sep 21 2024

Recap on Bayesian Statistics

베이즈에 대한 Recap 을 하겠습니다.

Frequentist :

- 확률들을 Long-run frequencies (같은 사건을 굉장히 반복했을 때 사건이 일어나는 비율) 으로 인식합니다.
- 확률변수 $\mathbf{X}$ 가 있다면, 이것과 관련된 모수인 θ 를 Fixed Parameter, Constant 으로 인식합니다.
- 목표 : 빈도의 보장을 갖는 방법론들을 만드는 것

Bayesian :

- 확률을 주관적인 Degree of Belief (Prior) 으로 정의합니다.
- 확률변수 $\mathbf{X}$ 가 있다면, 이것과 관련된 모수 (Parameter) 인 θ 를 확률변수, 그것의 모수 (Hyperparameter) 도 확률변수 으로 인식합니다.
- 목표 : 주관적인 신념을 토대로 분석하는 것

Recap on Bayesian Statistics

모수 자체를 확률변수로 보기 때문에, 저희는 베이즈 정리를 통해서 Posterior Distribution 을 다음과 같이 정리할 수 있습니다.

$$\pi(\theta | \mathbf{X}) = \frac{f(\mathbf{X} | \theta)p(\theta)}{\int f(\mathbf{X} | \theta)p(\theta)d\theta} = \frac{f(\mathbf{X} | \theta)p(\theta)}{f(\mathbf{X})} \propto f(\mathbf{X} | \theta)p(\theta)$$

- $\pi(\theta | \mathbf{X})$: Posterior Density (저희가 궁극적으로 궁금한 것!)
- $f(\mathbf{X} | \theta)$: Likelihood
- $p(\theta)$: Prior (저희의 주관적인 믿음)
- $\int f(\mathbf{X} | \theta)p(\theta)d\theta$: Normalizing Constant
- $f(\mathbf{X} | \theta)p(\theta)$: Kernel of Posterior Density

Proportional 에서 모든 함수는 θ 에 대한 함수입니다.

Recap on Bayesian Statistics (Prior)

$$\pi(\boldsymbol{\theta} \mid \mathbf{X}) \propto f(\mathbf{X} \mid \boldsymbol{\theta})p(\boldsymbol{\theta})$$

- 모수가 이제는 확률변수로 취급되기 때문에 θ 역시 확률분포를 가져야합니다.
- 그럼 Prior 설정은 어떻게 하면 좋을까요?
 - 연구자의 임의로 Prior 를 설정할 수 있습니다.
 - 모수의 성질에 알맞게 설정을 하는 것이 가장 좋습니다.
 - 예로 $\theta > 0$ 이라면, $\theta \sim \Gamma(a, b)$ 와 같이 0 이상에 있는 분포로 설정하는 것이 더 좋습니다.
 - 이것을 Likelihood 와 결합하면 Posterior 가 됩니다.
 - Prior 의 영향력을 최대한 줄이는 것이 베이지에서의 관건이며, 이를 **Non-informative Prior** 이라고 부르기도 합니다.

Recap on Bayesian Statistics (Likelihood)

$$\pi(\boldsymbol{\theta} \mid \mathbf{X}) \propto f(\mathbf{X} \mid \boldsymbol{\theta})p(\boldsymbol{\theta})$$

- $\mathbf{X}$ 에 대한 식으로 바라본다면 Joint Distribution 식입니다.
- $\boldsymbol{\theta}$ 에 대한 식으로 바라본다면 우도함수 입니다.
- 모수 값을 모를 때에 주어진 데이터를 넣었을 때 가장 알맞는 모수 값이 무엇인지에 대한 수치입니다.
- $f(\mathbf{X} \mid \boldsymbol{\theta})$ 가 아닌 $L(\boldsymbol{\theta} \mid \mathbf{X})$ 으로 표기할 때도 있습니다.
- 이 값을 최대화 시키는 $\boldsymbol{\theta}$ 추정량을 MLE 이라고 부릅니다.

Recap on Bayesian Statistics (MCMC)

$$\pi(\boldsymbol{\theta} \mid \mathbf{X}) \propto f(\mathbf{X} \mid \boldsymbol{\theta})p(\boldsymbol{\theta})$$

- 기존에는 분모 부분이 존재를 하며, 그것을 저희는 Normalizing Constant 이라고 부르며, pdf 형태로 맞추기 위해서 존재합니다.
- 하지만 MCMC 의 경우에는 위와 같은 Un-normalized Density 에도 사용이 가능합니다.
- 베イズ에서 Posterior 를 구하기 위한 다른 기법을 사용하려면 반드시 Normalizing Constant 를 구해야되지만, 이것을 MCMC 의 경우 안 구해도 되기에 굉장히 유용하다고 할 수 있습니다.

Conjugate Prior

Posterior 와 Prior 가 똑같은 Family of Distribution 을 따라간다면, 그것을 저희는 Conjugate Prior 이라고 부릅니다.

즉 Posterior 과 Prior 분포 둘다 정규분포를 따르게 된다면 이것을 Conjugate Prior 라고 둘 수가 있는 것입니다.

- Likelihood 와 Prior 둘다 확률분포이기에 곱하는 것은 굉장히 복잡한 값이지만, 잘 알려진 케이스의 경우 이전 케이스를 갖다 사용하면 됩니다.
- Conjugate Prior 도 그 예시 중 하나이며, Likelihood 와 Prior 가 어떠한 분포를 따른다는 것을 이미 알고 있다면 Posterior 가 어떤 형태일지 아는 경우가 포함되어 있습니다.

Conjugate Prior (Examples)

- 기본적으로 Likelihood 는 데이터에 따라서 다르기에 저희가 임의로 고르지 못합니다.
- 하지만 Prior 의 경우 저희가 마음대로 고를 수 있기에 Likelihood 와 어울리는 형태로 만들어서 Posterior 분포를 Conjugate Prior 를 이용해서 구할 수 있게 됩니다.

Likelihood	Prior	Posterior	Parameter
Binomial	Beta	Beta	$B(n, \mathbf{p})$
Poisson	Gamma	Gamma	$\text{Pois}(\lambda)$
Normal	Inverse-Gamma	Inverse-Gamma	$N(\mu, \theta)$
Normal	Normal	Normal	$N(\theta, \sigma^2)$

Conjugate Prior for Normal Mean

필요한 것들 :

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left(-\frac{(x - \theta)^2}{2\sigma^2}\right)$$

Formulating the Posterior

베이즈 정리를 다시 갖고오자면, 다음과 같습니다.

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)}$$

이것을 이용해서 저희는 Posterior 를 구축하는 것이 가능하며, Conjugate Prior 이외의 예시에서도 보여드리겠습니다. (1주차 때 했던 겁니다) 1000 개의 제품들 중에서 145 개 만이 불량이라고 생각하겠으며, 불량일 확률은 베타 분포를 따른다는 Prior 를 가정하겠습니다. 그럼 이것을 다음과 같은 Hierarchical Model 을 구성할 수 있습니다.

Formulating the Posterior (Example 1)

$$\mathbf{X} \sim \text{Binom}(1000, \theta)$$

$$\theta \sim \text{Beta}(a, b)$$

- $f(\mathbf{X} \mid \theta) \propto \theta^{\mathbf{X}}(1 - \theta)^{1000 - \mathbf{X}}$
- $p(\theta) \propto \theta^{a-1}(1 - \theta)^{b-1}$
- $\pi(\theta \mid \mathbf{X}) \propto f(\mathbf{X} \mid \theta)p(\theta) = \theta^{a+\mathbf{X}-1} \cdot (1 - \theta)^{b+1000-\mathbf{X}-1}$

$$\propto \theta^{a+\mathbf{X}-1} \cdot (1 - \theta)^{b+1000-\mathbf{X}-1} \cdot \frac{\Gamma(a + \mathbf{X} + b + 1000 - \mathbf{X})}{\Gamma(a + \mathbf{X}) \cdot \Gamma(b + 1000 - \mathbf{X})}$$
$$\sim \text{Beta}(a + \mathbf{X}, b + 1000 - \mathbf{X})$$

Formulating the Posterior (Example 1)

그럼 저희는 Posterior 의 분포를 다음과 같이 정리할 수 있습니다.

$$\theta \mid \mathbf{X} \sim \text{Beta}(a + \mathbf{X}, b + 1000 - \mathbf{X})$$

1000 개 중에서 145 개 가 불량이기에 $\mathbf{X} = 145$ 으로 둘 수 있으며 Beta 분포의 평균을 이용할 수 있습니다.

$$E[\theta \mid \mathbf{X}] = \frac{a + \mathbf{X}}{a + b + 1000}$$

그러면 a 와 b 값들을 어떻게 설정하느냐에 따라서 이 값도 달라지게 됩니다.

Formulating the Posterior (Hierarchical Model))

이런 식으로 Likelihood 와 Prior 가 둘다 주어지게 된다면 Posterior 를 당연히 손쉽게 구할 수 있습니다.

Prior 역시 분포를 따르며, 그 분포에 있는 모수인 Hyperparameters a, b 역시 분포를 따른다고 봐야 합니다.

전체적인 틀을 짜서 Posterior 를 구축하게 되는 것을 Hierarchical Model 이라고 부릅니다. 즉

$$\mathbf{X} \sim \text{Binom}(1000, \theta)$$

$$\theta \sim \text{Beta}(a, b)$$

$$a \sim \Gamma(c, d), \quad b \sim \Gamma(e, f)$$

하지만 실제 상황에서는 Prior 를 이전 슬라이드와 같이 구체적으로 알 수 있는 상황은 굉장히 드물기에 데이터를 통해서 Prior 를 설정하는 경우가 자주 나옵니다. → Empirical Bayes!

Formulating the Posterior (Empirical Bayes)

저희 분포들을 다음과 같이 표현할 수 있습니다.

$$X \mid \theta \sim f(X \mid \theta)$$

$$\Theta \mid \gamma \sim h(\theta \mid \gamma)$$

γ 값 자체를 아예 데이터를 이용해서 추정을 해버리는 것!

$$g(x, \theta \mid \gamma) = f(x \mid \theta) \cdot h(\theta \mid \gamma)$$

$$m(x \mid \gamma) = \int_{-\infty}^{\infty} f(x \mid \theta) \cdot h(\theta \mid \gamma) d\theta = \int_{-\infty}^{\infty} g(x, \theta \mid \gamma) d\theta$$

그럼 $m(x \mid \gamma)$ 를 통해서 γ 를 추정할 수 있게 됩니다.
(보통은 MLE 를 사용합니다)

Formulating the Posterior (Example 2)

$$X_i \mid \lambda \sim \text{Pois}(\lambda), \quad i = 1, \dots, n$$

$$\Lambda \mid b \sim \text{Gamma}(1, b)$$

$$g(X \mid \lambda) = \frac{\lambda^{n \cdot \bar{x}}}{x_1! \cdots x_n!} \cdot e^{-n \cdot \lambda}, \quad \bar{x} = \frac{1}{n} \cdot \sum_{i=1}^n x_i$$

$$\begin{aligned} m(x \mid b) &= \int_0^\infty g(x \mid \lambda) \cdot h(\lambda \mid b) d\lambda \\ &= \int_0^\infty \frac{1}{x_1! \cdots x_n!} \cdot \lambda^{n \cdot \bar{x} + 1 - 1} \cdot e^{-n \cdot \lambda} \cdot \frac{1}{b} \cdot e^{-\lambda/b} \cdot d\lambda \\ &= \frac{\Gamma(n \cdot \bar{x} + 1) \cdot [b/(nb + 1)]^{n \cdot \bar{x} + 1}}{x_1! \cdots x_n!} \end{aligned}$$

$$\frac{\partial}{\partial b} \log(m(x \mid b)) = -\frac{1}{b} + (n \cdot \bar{x} + 1) \cdot \frac{1}{b \cdot (bn + 1)} \stackrel{\text{set}}{=} 0$$

=

Formulating the Posterior (Example 2)

$$\begin{aligned}\hat{b} = \bar{x}, \quad k(\lambda \mid x, \hat{b}) &\propto g(x, \lambda) \cdot h(\lambda \mid \hat{b}) \\ &\propto \lambda^{n \cdot \bar{x} + 1 - 1} \cdot e^{-\lambda \cdot [n + 1 / \hat{b}]} \sim \text{Gamma} \left(n \cdot \bar{x} + 1, \frac{\hat{b}}{n \cdot \hat{b} + 1} \right)\end{aligned}$$

$$\hat{\lambda} = [n \cdot \bar{x} + 1] \cdot \frac{\hat{b}}{n \cdot \hat{b} + 1} = (n \cdot \bar{x} + 1) \cdot \frac{\bar{x}}{n \cdot \bar{x} + 1} = \bar{x}$$

Empirical Bayes Estimator 는 MLE 와 똑같다!

Stochastic Process (확률 과정)

확률과정은 무엇일까요?

- 확률과정 $\{X_t, t \in T\}$: Collection of Random Variables, 즉 확률변수들을 나열해 놓은 것입니다.
- t 에 따라서 변화되는 것을 의미하며, 보통 t 는 시간을 의미합니다. 위의 경우 그럼 X_t 를 t -시점에서의 X 값을 의미하며, $\{X_t, t \in T\}$ 는 시간의 변화에 따른 확률변수 값의 변화를 나타냅니다.
- X_t 는 유한/무한 집합 (Finite/Infinite Set) 이 될 수 있지만 지금은 유한한 상황을 가정하겠습니다.
- T 가 Countable Set이면 그 확률 과정은 Discrete-time 확률 과정입니다. 즉 시간이 $\{0, 1, 2, \dots\}$ 와 같은 형태일 때.
- T 가 무한집합이면 그 확률 과정은 Continuous-time 확률 과정입니다. 즉 시간이 $[0, \infty)$ 와 같은 형태일 때.

Stochastic Process (확률 과정)

확률과정은 그러면 다음과 같이 $X_0, X_1, \dots, X_{n-1}$ 까지의 데이터가 있다면 X_n 을 구하기 위해서는 저희가 가진 데이터를 토대로 활용을 진행하게 됩니다.

$$P(X_n | X_0, X_1, X_2, \dots, X_{n-1})$$

확률과정의 예시는 뭐가 있을까요?

- Random Walk
- Poisson Process
- Brownian Motion
- Markov Process

이 중에서도 저희는 Markov Process 에 해당하는 Markov Chain 에 대해서 더 자세히 알아볼 예정입니다.

Markov Chain

일반적으로 X_n 의 값은 모든 이전 확률 변수들에 영향을 받습니다.
Markov Chain 은 X_n 의 값이 오로지 이전 시점의 값인 X_{n-1} 에만 영향을 받는 것을 의미합니다.

$$P(X_n | X_0, X_1, \dots, X_{n-1}) = P(X_n | X_{n-1})$$

이것을 다르게 말하자면 X_{n-1} 이 주어졌다면 $X_0, X_1, \dots, X_{n-2}$ 과 X_n 은 독립입니다.
즉 한 시점의 값이 직전 시점의 값에만 영향을 받는 과정입니다.

Markov Chain (Example)




Figure: Markov Chain 예시

Markov Chain (Example)

이전 슬라이드에서의 예시를 정리해서 말하자면, Rainy 인 상황을 X_n 이라고 칭하면 X_{n+1} 의 상황이 될 수 있는 것은 Rainy, Cloudy, 혹은 Sunny 이겠죠.

해당 상황에서의 확률들은

Rainy : 0.5, Cloudy : 0.3, Sunny : 0.2

합하면 1.0 이 됩니다. 즉 X_{n+1} 의 확률을 위해서는 X_n 에서 무엇이 있는지만 알아도 확률이 어차피 1.0 으로 충분하기에 현 시점만 알아도 충분하다는 의미입니다.

이러한 것을 저희는 **Transition Probability** 으로 표현하는 것이 가능합니다.

Markov Chain (Transition Probability)

One-step Transition Probability 를 다음과 같이 정의하겠습니다.

$$p_{ij} = P(X_n = j \mid X_{n-1} = i), \quad p_{ij} \geq 0, \quad \sum_{j=0}^{\infty} p_{ij} = 1$$

이것을 해석하자면, 현 시점인 X_{n-1} 이 State i 일 때, 다음 시점인 X_n 이 State j 일 확률이 p_{ij} 입니다.

이 Transition Probability 를 Matrix 형태로 표현하면 $\mathbf{P}$ 의 Matrix 로 표현이 가능합니다.

- $\mathbf{P}$ 의 각 행의 원소들의 합은 항상 1 이다.
- 각 열의 원소들의 합은 1 일 필요가 없다.

그럼 one-step transition probability matrix 은 $\mathbf{P}$ 으로,
n-step transition probability matrix 은 $\mathbf{P}^{(n)}$ 으로 부를 수가 있습니다.

Markov Chain (Transition Probability)

베이지스 통계에서는 다른 Notation 들을 사용하기에 이 점 유의하시면 좋습니다.

- $X_n \rightarrow X^{(t)}$
- $P_{ij}^{(t)} = p(X^{(t+1)} = j \mid X^{(t)} = i)$

Chapman-Kolmogorov Equation 에 의하면, 다음과 같은 형태로 Transition Probability 를 적는 것이 가능합니다.

$$\mathbf{P}^{(n)} \times \mathbf{P}^{(m)} = \mathbf{P}^{(n+m)}$$

이것을 저희의 n-step probability matrix 에 바로 적용하면,

$$\mathbf{P}^{(n)} = \mathbf{P} \times \mathbf{P}^{(n-1)}$$

즉 저희는 다음만 알면 Markov Chain 을 완전히 정의하는 것이 가능합니다.

- 초깃값 X_0 or $X^{(0)}$
- One-step transition probability matrix $\mathbf{P}$

Markov Chain (Irreducibility)

Irreducible 한 Markov Chain 은 아무 State i 에서 모든 State j 까지 도달하는 것이 가능합니다.

즉 모든 State i, j 들은 i -th state 에서 시작한 다음에 어떻게든 j -th state 까지 도달하는 것이 가능하다는 의미를 가집니다.

- 다른 말로 Class 가 1 개인 Markov Chain 을 의미합니다.
- 하지만 이것은 $\forall i, j, \quad p_{ij} > 0$ 와는 다른 의미를 가집니다.

Markov Chain (Limiting Distribution)

Limiting Distribution π_j 는 어떤 Markov Chain 이 $n \rightarrow \infty$ 으로 갈 때에 나오는 State 가 j 일 확률을 의미합니다.

$$\pi_j = \lim_{n \rightarrow \infty} P_{ij}^{(n)} = \lim_{n \rightarrow \infty} P(X_n = j \mid X_0 = i)$$

- Limiting Distribution 의 경우 존재하지 않을 수도 있습니다.
- 초깃값에 영향을 받지 않습니다.
- Markov Chain 내에서 자신으로 돌아오는 경로를 하나라도 가지고 있다면 해당 State 은 항상 Limiting Distribution 을 가지고 있습니다.

Markov Chain (Stationary Distribution)

Stationary Distribution π_j 는 어떤 Markov Chain 이 해당 State j 를 방문하는 비율을 확률로 둔 것으로 정의가 됩니다.

$$\pi_j = \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{t=0}^n P(X_t = j \mid X_0 = i)$$

이것들을 쉽게 생각해서 Long-term Proportion 들이라고 생각해도 됩니다.

- Stationary Distribution 의 경우 $\pi = \pi \mathbf{P}$ 를 만족하기 때문에 $\sum_{i=0}^N \pi_i = 1$ 만 만족한다면 이 식을 통해서 구하는 것이 가능합니다.
 - $\pi = [\pi_0, \pi_1, \dots, \pi_N]$ where N is Total Number of States.
- Irreducible Markov Chain 의 경우 항상 Stationary Distribution 을 가집니다 (한번 짚은 모든 State 을 결국에는 방문하기에).

Markov Chain (Aperiodicity)

어떠한 State 에 있던 간에 다른 State 으로 가기까지 걸리는 주기 (Period) 입니다.

- Period 의 경우 ≥ 2 이면, Markov Chain 이 어떠한 패턴을 가지면서 움직이게 되며, 이것은 다른 의미로 주기성이 생긴다는 의미를 가집니다.
- Markov Chain 내의 모든 State 들의 Period 가 1 이라면 해당 Markov Chain 은 Aperiodic 이라고 부릅니다.
- Irreducible Markov Chain 에서의 모든 State 들이 자기 자신으로 돌아오는 경로를 적어도 하나를 가지고 있다면 반드시 Aperiodic 합니다.

Markov Chain (Ergodicity)

쉽게 생각해서 Irreducible 이랑 Aperiodic 을 둘다 만족한다면 Ergodic 하다고 보면 됩니다.

이것이 만족이 되면 다음이 성립됩니다.

- $\frac{1}{N} \sum_{n=1}^N f(X_n) \rightarrow E_{\pi}[f(X)]$ almost surely as $N \rightarrow \infty$
- $P(X_n = j \mid X_0 = i) \rightarrow \pi_j$, as $n \rightarrow \infty$

다른 말로, Ergodic Markov Chain 에서는 Stationary Distribution 과 Limiting Distribution 이 똑같습니다.

즉 Ergodic Markov Chain 에서는 Stationary Distribution 을 구한 다음에 그것을 Limiting Distribution 으로 해석하는 것도 가능하다는 의미입니다.

Markov Chain (Time Reversible)

저희는 여태까지 Markov Chain 의 순서가 순차적으로 커지는 것에 대해서 다루었습니다.

하지만 Time Reversible 한 Markov Chain 의 경우 반대의 방향 (Reversed Version) 으로 이동해도 Markov Chain 이 되어야 합니다.

$$\cdots, X_{n-2}, X_{n-1}, X_n, \cdots, \leftrightarrow \cdots, Y_n, Y_{n-1}, Y_{n-2}, \cdots$$

여기에 State 들의 값들 대신에 Transition Probability 를 활용한다면 Reversed 된 Markov Chain 의 Transition Probability 를 q_{ij} 으로 다음과 같이 정의가 가능합니다.

$$\begin{aligned} q_{ij} &:= P(Y_m = j \mid Y_{m-1} = i) = P(X_{n-m} = j \mid X_{n-m+1} = i) \\ &= P(X_n = j \mid X_{n+1} = i) \end{aligned}$$

Markov Chain (Time Reversible)

Time Reversible 한 Markov Chain 이 만족되기 위해서는 $p_{ij} = q_{ij}$ 가 만족이 되면 됩니다.

$$p_{ij} = P(X_n = j \mid X_{n+1} = i) = \frac{P(X_n = j)P(X_{n+1} = i \mid X_n = j)}{P(X_{n+1} = i)} = \frac{\pi_j p_{ji}}{\pi_i}$$

위의 식을 정리하자면,

$$p_{ij} = \frac{\pi_j p_{ji}}{\pi_i}, \quad \pi_j p_{ji} = \pi_i p_{ij}$$

마지막 식을 Detailed Balance Condition 이라고 부르기도 합니다.

Markov Chain (Example Problem)

야바위는 과연 Markov Chain 일까요?

- 컵이 3개, 공이 1개일 때의 경우 야바위는 Markov Chain 인가?
- Transition Probability Matrix $\mathbf{P}$ 를 구하라.
- 이것은 Irreducible 한 Markov Chain 인가?
- 이것은 Aperiodic 한 Markov Chain 인가?
- 이것은 Time reversible 한 Markov Chain 인가?

Monte Carlo

Monte Carlo 방법론이란 무엇일까요?

- Monte Carlo 란 여러번 뽑아서 (Random Simulations) 문제를 Computationally 하게 해결하는 방법론을 의미합니다.
- LLN 이란 Law of Large Numbers, 대수의 법칙을 의미하며 이것을 활용시킵니다.
- Monte Carlo Integration 이란 $\int_0^1 g(x)dx$ 인 적분식의 근사값을 구하는 것을 의미하며, 이것은 대수의 법칙을 이용해서 $\frac{1}{n} \sum_{i=1}^n g(U_i) \rightarrow \int_0^1 g(x)dx$ 을 통해서 구할 수가 있습니다.
- 여기에서 $U_i \overset{i.i.d}{\sim} \text{Unif}(0, 1)$
- 즉 저희는 적분식을 $g(U_i)$ 라는 확률변수의 평균으로 표현이 가능하기에 해당 확률변수의 표본 평균을 구해서 평균 값을 추정하는 것입니다.
- 사실 이것은 굉장히 유용하며, 적분이 불가능한 정규분포 pdf 도 이런 식으로 근사가 가능합니다.
- 하지만 이것은 추정이기 때문에 이에 해당하는 오차 역시 존재합니다.

Monte Carlo

다시 말해, $U_i \stackrel{i.i.d}{\sim} \text{Unif}(0, 1)$ 이기에 이에 해당하는 pdf 를 $f(x) = \mathbf{I}(0 < x < 1)$ 이라고 부르겠습니다.

$$\int_0^1 g(x) dx = \int_0^1 f(x) g(x) dx = E[g(U)]$$

가 성립하기에 $n \rightarrow \infty$ 일 수록 대수의 법칙으로 인해서

$$\frac{1}{n} \sum_{i=1}^n g(U_i) \xrightarrow{P} E[g(U)]$$

Monte Carlo (정규분포)

이전 슬라이드에서도 말했 듯이, 정규분포의 pdf 식을 손으로 적분하는 것은 불가능합니다.

$$\int_0^{\infty} g(x) dx = \int_0^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}x^2\right) dx$$

그래서 적분하는 구간을 $[0, 1]$ 으로 바꿔주기 위해서 $y = \frac{1}{x+1}$ 으로 치환할 것이며, 즉 $x = \frac{1}{y} - 1$ 이며 $dx = -\frac{1}{y^2} dy$ 으로 바꿔서 Jacobian 을 활용하면,

$$\int_0^{\infty} g(x) dx = \int_0^1 g\left(\frac{1}{y} - 1\right) \left(\frac{1}{y^2}\right) dy = E\left[g\left(\frac{1}{Y} - 1\right) \cdot \frac{1}{Y^2}\right]$$

$Y \sim \text{Unif}(0, 1)$

이것을 통해서 추정을 하는 것이 가능합니다.

Monte Carlo (정규분포)

이 값을 구하는데 있어서 저희는 치환을 $y = \frac{1}{x+1}$ 인 것을 사용했지만 이것은 상황에 맞게끔 더 좋은 값들도 가져올 수 있습니다.
이것은 결국 분산을 살펴서 어떤 것이 더 좋은 추정치인지 알 수가 있습니다.

$$y = \frac{x}{x+1}, x = \frac{y}{1-y}, dx = \frac{1}{(1-y)^2} dy$$
$$\int_0^{\infty} g(x) dx = \int_0^1 g\left(\frac{y}{1-y}\right) \frac{1}{(1-y)^2} dy =$$
$$E\left[g\left(\frac{Y}{1-Y}\right) \frac{1}{(1-Y)^2}\right]$$

분산을 확인해서 어떤 것이 더 좋은 추정 방법인지 확인하면 됩니다.

Monte Carlo (Estimating π)

이 방법을 이용해서 π 의 값도 쉽게 구할 수가 있습니다.

- 동그라미의 넓이는 πr^2 인 것은 누구나 알고 있습니다.
- 추가적으로 x-y 축에서 동그라미의 영역은 $x^2 + y^2 \leq 1$ 입니다.
- 이 점을 이용해서 π 값을 추정하겠습니다.
- 동그라미 중에서도 제1사분면에 들어가는 부분들만 생각하겠습니다.
그럼 해당 부분의 넓이는 $\pi r^2 \cdot 0.25 = \frac{\pi}{4}$ 입니다.
- 해당 영역에서 동그라미를 딱 둘러싸는 정사각형의 넓이는 1 입니다.
- 정사각형에서 뽑는 것은 쉽습니다, 그저 균일분포에서 뽑으면 되기
때문입니다.
- 정사각형에서 뽑아서 동그라미안에 들어갈 확률은 그럼 동그라미의
넓이 나누기 정사각형의 넓이, 즉 $\frac{\pi}{4}$ 가 됩니다.

Monte Carlo (Estimating π)

수식적으로 보이자면, 다음과 같습니다.

$$X \stackrel{i.i.d}{\sim} \text{Unif}(0, 1), \quad Y \stackrel{i.i.d}{\sim} \text{Unif}(0, 1)$$

$$\frac{1}{n} \sum_{i=1}^n \mathbf{I}(X_i^2 + Y_i^2 \leq 1) \rightarrow \mathbb{E}[\mathbf{I}(X^2 + Y^2 \leq 1)] = \frac{\pi}{4}$$

그럼 알고리즘은 다음과 같이 구성이 가능합니다.

- Generate $(u_1, v_1), \dots, (u_n, v_n), U, V \sim \text{Unif}(0, 1)$
- $\pi = 4 \times \frac{\sum_{i=1}^n \mathbf{I}(u_i^2 + v_i^2 \leq 1)}{n}$