

베이지스 튜터링 3주차

Jaewoo Shin

Sep 28 2024

Markov Chain Monte Carlo (MCMC)

이전 기법들에 의하면, 확률분포들이 깔끔하게 구해졌지만, 베이지 통계에서는 pdf 들이 굉장히 복잡한 형태를 주로 다루게 되며, 이러한 경우에는 **MCMC** 를 사용하게 됩니다.


MCMC 의 경우에는 Irreducible and Aperiodic 한 Markov Chain 의 Stationary Distribution 인 π 으로부터 Random Sample 을 생성하는 기법입니다.

- 직전의 값을 이용하기 때문에 i.i.d sampling 을 불가능하게 만들며, 즉 이것은 Dependent Sampling 기법입니다.
- 초깃값에도 영향을 받게 됩니다.

실제로 사용할 때 저희는 Stationary Distribution π 에서 뽑는 것을 목표로 하며 이것이 i.i.d 하지는 않지만 많이 뽑다 보면은 π 에서 뽑는 것이라 똑같은 효과를 불러일으키는 것이 목표입니다.

$$E[f(X)] = \frac{1}{T} \sum_{t=1}^T f(X^{(t)}), \quad X^{(1)}, \dots, X^{(T)} \sim \pi$$

Markov Chain Monte Carlo (MCMC)



결론적으로는 Irreducible and Aperiodic 한 Markov Chain 에서 뽑은 값들이 i.i.d 하게 뽑는 것이 거의 불가능해보이는 Posterior Distribution 의 샘플들이며, 이 값들을 분포로 표현해서 Posterior Distribution 에 대한 정보를 얻는 것이 목표입니다.

Markov Chain Monte Carlo (MCMC)

Posterior $\propto$ Prior $\times$ Likelihood

지금은 별로 안 복잡해보이지만 다변량, Inverse-Gamma, 등이 들어가기
싶가하면 Posterior 분포는 매우 복잡한 형태를 띄게 될 것입니다.

예: Normal Likelihood with known Variance, where prior is normal, 그럼
Posterior 분포의 파라미터는 다음과 같습니다.

$$\frac{1}{\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}} \left(\frac{\mu_0}{\sigma_0^2} + \frac{\sum_{i=1}^n x_i}{\sigma^2} \right), \left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2} \right)^{-1}$$

Metropolis-Hastings Algorithm (Discrete)

MCMC 기법들 중에서 가장 대중적으로 사용되고 있는 알고리즘 입니다.

우선은 Discrete 한 경우를 살펴겠습니다.

- 1 Initialize $t = 0, X^{(0)} = x_0 \in X$
- 2 Sample $X' \sim Q(X' | X^{(t)})$
- 3 Sample $U \sim \text{Unif}(0, 1)$
- 4 If $U < \frac{\pi(X') \cdot Q(X^{(t)} | X')}{\pi(X^{(t)}) \cdot Q(X' | X^{(t)})}$, then $X^{(t+1)} = X'$, else $X^{(t+1)} = X^{(t)}$
- 5 $t = t + 1$, Repeat 2 ~ 5 until $t = T$

Metropolis-Hastings Algorithm (Discrete)

- ① Initialize $t = 0, X^{(0)} = x_0 \in X$
 - $t = 0$ 시점에서 $X^{(t)}$ 값을 설정해주는 단계입니다.
 - Markov Chain 의 경우 첫번째 값인 Initial Value 가 무엇인지에 따라서 값이 변할 때가 많습니다.
 - 초깃값 설정이 그래서 중요하지만, t 를 굉장히 많이 증가할 경우에는 마지막 결과에는 큰 영향을 끼치지 않는으나 수렴의 속도에 영향을 줄 수 있는 요소이기는 합니다.

Metropolis-Hastings Algorithm (Discrete)

② Sample $X' \sim Q(X' | X^{(t)})$

- Q 의 경우 Markov Chain 내에서의 Transition Probability Matrix 입니다. MCMC 는 Irreducible 하기에 이것 역시 그것을 만족해줘야 합니다.
- 이것 이용해서 다음 후보 값인 X' 값을 구합니다.
- Transition Probability 의 경우 이전 값을 알아야 하기에 해당 값을 $X^{(t)}$ 으로 설정해줍니다.
- Q 의 경우에는 저희 맘대로 설정해줄 수 있지만, Symmetric 한 것이 가장 좋습니다 (차후에 설명).

Metropolis-Hastings Algorithm (Discrete)

③ Sample $U \sim \text{Unif}(0, 1)$

- 저희는 X' 값을 사용할지 안할지를 아직 안 정했으며 그것에 대한 여부를 Stationary Probability 에 대한 확률에 의해서 결정됩니다.
- 하지만 이것 역시 확률이기 때문에 $0 \sim 1$ 사이의 값이며 U 값과의 비교를 통해서 사용할지 안할지에 대한 여부를 결정해줍니다.
- 이 값의 경우 파라미터가 여러가지이면 따로따로 샘플을 해주는 것을 추천합니다.

Metropolis-Hastings Algorithm (Discrete)

- ④ If $U < \frac{\pi(X') \cdot Q(X^{(t)}|X')}{\pi(X^{(t)}) \cdot Q(X'|X^{(t)})}$, then $X^{(t+1)} = X'$, else $X^{(t+1)} = X^{(t)}$
- 여기에서 Stationary Probability 에 넣는 값을 $\alpha = \frac{\pi(X') \cdot Q(X^{(t)}|X')}{\pi(X^{(t)}) \cdot Q(X'|X^{(t)})}$ 이라고 부르며, 이것을 전에 구했던 U 값과 비교합니다.
 - 만약에 X' 의 값이 $X^{(t)}$ 보다 적절하면 $\pi(X') > \pi(X^{(t)})$ 이며 이 경우에는 $\alpha > 1$ 를 기대할 수 있습니다.
 - 알고리즘에는 안 적었지만 α 자리에 $\min(1, \alpha)$ 가 들어가는 것이 정확하지만, 실행할 때는 크게 상관없습니다.
 - $\alpha > 1 \rightarrow 1$, 무조건 사용
 - $\alpha < 1 \rightarrow \alpha$, α 의 확률로 사용
 - 저희는 결국에는 $P(U < \alpha)$ 를 구하는 것입니다.
 - α 값을 살피면 Q 도 포함이 되어 있으며, 만약에 Symmetric 하다면 해당 값들은 약분이 가능해집니다.

Metropolis-Hastings Algorithm (Discrete)

- ⑤ $t = t + 1$, Repeat 2 ~ 5 until $t = T$
- 샘플들을 여러번 뽑다 보면은 Stationary Distribution 에서 뽑는 효과를 보게 될 것입니다.
 - 여기에서 저희의 Stationary Distribution 은 Posterior Distribution 이기에 Posterior Distribution 에서 뽑는 것이라 똑같은 효과를 볼 수가 있습니다.

Metropolis-Hastings Algorithm (Continuous)

이제는 Continuous-case 를 살피겠습니다.

- 1 Initialize $t = 0$, $X^{(0)} = x_0 \in X$
- 2 Sample $X' \sim q(X' | X^{(t)})$
- 3 Sample $U \sim \text{Unif}(0, 1)$
- 4 If $U < \frac{\pi(X') \cdot q(X^{(t)} | X')}{\pi(X^{(t)}) \cdot q(X' | X^{(t)})}$, then $X^{(t+1)} = X'$, else $X^{(t+1)} = X^{(t)}$
- 5 $t = t + 1$, Repeat 2 ~ 5 until $t = T$

$Q \rightarrow q$, 즉 Proposal Density 으로 바뀌었다는 것 이외에는 바뀌게 없습니다.

Metropolis-Hastings Algorithm (Continuous)

② Sample $X' \sim q(X' | X^{(t)})$

- $q(X' | X^{(t)})$: 평균이 $X^{(t)}$ 인 Proposal Density q 에서 $X^{(t)}$ 를 생성합니다.
- q 는 Discrete 와 똑같이 저희가 원하는 대로 설정해주면 되지만, Symmetric 해야지 약분이 되며 연산적으로 편해집니다.
- Symmetric Density 를 가지는 Proposal 중에서 가장 많이 사용되는 것은 바로 정규분포입니다.
- 만약에 Target Distribution 을 따르는 모수들에 제약조건이 있다면 그 조건에 맞게끔 Proposal Density 에서도 샘플링을 진행해야 됩니다.
 - 예: 푸아송 분포가 Target Distribution 이기에 무조건 양수이어야 한다.

Metropolis-Hastings Algorithm

$$\alpha = \frac{\pi(X') \cdot Q(X^{(t)} | X')}{\pi(X^{(t)}) \cdot Q(X' | X^{(t)})}$$

이 값의 분자와 분모가 만약에 너무 작아서 Underflow 가 발생해서 $\alpha = \frac{0}{0} = \text{NaN}$ 이 나올 수도 있습니다.

이것을 방지하기 위해서 다음과 같이 로그 함수를 활용하면 됩니다.

- α 대신에 $\log(\alpha)$
- U 대신에 $\log(U)$
- Monotone 이기에 $\log(U) < \log(\alpha)$ 으로 비교하면 됩니다.

Convergence of MCMC

MCMC 를 구축하는 것과 어떻게 알고리즘을 짜는지에 대해서 배웠습니다. 하지만 알고리즘 자체가 잘 흘러가고 있는지, Target Distribution π 에 잘 수렴하고 있는지, 언제부터 수렴을 하기 시작했는지, i.i.d 하게 뽑는 것이라 비슷하게 뽑혔는지 등에 관한 내용이 필요합니다.


이것을 알기 위해서는 다음을 살펴보면 됩니다.

- Trace plot
- Histogram
- Auto-correlation Plot (ACF Plot)
- Acceptance Probability
- Effective Sample Size (ESS)

위에 있는 것이 만족을 한다면, Posterior Mean, 95% HPD Interval 등을 확인해서 추정량과 추정 신뢰구간까지 파악할 수 있게 됩니다.

Trace Plot

기존에는 시간에 따라서 변화를 나타내지만, 여기에서는 MCMC 샘플을 뽑을 때마다의 변화를 보여주는 역할을 하며, `ts.plot()` 함수를 사용하면 됩니다.



Burn-in


MCMC 를 잘 구성시키면 위쪽 그림과 같이 나오게 되지만, 초깃값을 잘못 설정해서 바로 수렴하지 못하는 모습을 보일 때도 있으며, 수렴하는데까지 시간이 필요한 모습을 보이고 있습니다.

그렇기 때문에 수렴하지 못한 부분들을 제거하는 과정이 필요하며, 이것을 **Burn-in** 이라고 부릅니다. 이전 슬라이드에서의 중간 그림은 2000 때에 Burn-in 을 적용하는 것이 적절해보이며 나머지 값들이 저희의 MCMC 샘플이 되는 것입니다.

3번째 그림의 경우 전혀 수렴을 하지 못한 모습을 보이고 있습니다.



Histogram

MCMC 샘플들을 어느 정도 뽑았다면, 이게 과연 목표 분포와 얼마나 비슷한지 알기 위해서 히스토그램을 그려줍니다. Target Distribution 이 있다면 바로 비교도 가능합니다.



Auto-Correlation Plot

MCMC 는 i.i.d Sampling 기법이 아닙니다. 하지만 저희는 최대한 i.i.d 하게 뽑고 싶기 때문에 뽑힌 샘플들 간의 Correlation 을 확인하기 위해서 ACF Plot 을 확인해줍니다.



Acceptance Probability / Rate

MH-Algorithm 의 경우 X' 을 Accept, 혹은 Reject 을 하는 프로세스를 반복합니다.

- $U < \alpha$ 이면 Accept 합니다.
- $U \geq \alpha$ 이면 Reject 합니다.

Accept 하는 횟수와 전체 돌린 횟수의 비율을 Acceptance Rate 이라고 합니다.

$$\text{Acceptance Rate} = \frac{\text{Total\#ofAcceptance}}{\text{Total\#ofIterations}}$$

바람직한 Acceptance Rate 는 20% ~ 50% 이며, 이 이상이면 너무 Stochastic 해지며 이하이면 너무 한 곳에 머무르기 때문에 바람직하지 않습니다.

Effective Sample Size (ESS)

MCMC 는 Dependent Sampling 이기에 Independent Sampling 한 경우보다 성능이 떨어집니다. ESS 는 Independent Sampling 에 비해서 얼마나 성능이 떨어지는지를 알려주는 수치입니다.

예시로 샘플을 10000 개 만들었지만 $ESS = 2000$ 이면 제가 가진 만개의 샘플은 i.i.d 하게 2000 만큼 뽑은 것과 비슷하다는 의미입니다.

ACF 값이 커지면 커질 수록 ESS 는 작아지게 됩니다.

실전 예시 1

Generate 10000 MCMC Samples of the following random variable.

$$0.5 \cdot N(1, 0.3) + 0.5 \cdot N(3, 0.3)$$

실전 예시 2

Cauchy 분포의 pdf 는 다음과 같습니다.

$$f(x) = \frac{1}{\theta \cdot \pi \cdot [1 + (\frac{x-\eta}{\theta})^2]}, \quad -\infty < x < \infty, \theta > 0$$

이때 $\theta = 2$, $\eta = 0$ 일 때 10,000 개 만큼의 MCMC Sample 을 적절한 Acceptance Probability 를 통해서 만들어주시오.