

베이즈 튜터링 6주차

Jaewoo Shin

November 27, 2024

Bayes for Big Data

베이지스 방법론은 보통은 Monte-Carlo Simulation 을 기반으로 진행이 됩니다. 이것은 **MCMC** 를 진행하면 특히나 중요합니다. 이에 대한 단점은 뭐가 있을까요?

- 모든 데이터에 대해서 다루기에는 Simulation 이 너무 비싸다.
- 머신러닝에서 DataLoader 에 모든 데이터를 Sequentially 하게 넣는 것이 비효율적인 이유와 비슷하다.
- 그럼 우리도 비슷하게 데이터를 나눠서 진행하면 좋지 않을까?

Consensus Monte Carlo

- 1 Break the data into groups ("shards").
- 2 Give each shard to a processor which does a full Monte Carlo simulation from posteriors.
- 3 Combine the posterior simulations from all shards.

Consensus Monte Carlo

그럼 각 Shard 마다 데이터가 나눠져 있다. 이것을 $\mathbf{X}_s$ 라 부를 수도 있다.

Full Data : $\mathbf{X} = \mathbf{X}_1, \dots, \mathbf{X}_S$

Full Posterior :

$$\pi(\boldsymbol{\theta} | \mathbf{X}) = \prod_{s=1}^S \pi_s(\boldsymbol{\theta} | \mathbf{X}_s) \propto \prod_{s=1}^S f(\mathbf{X}_s | \boldsymbol{\theta}) p^{1/S}(\boldsymbol{\theta})$$

여기에서의 Assumption 은 당연히도 Conditional 끼리는 Independence 가 존재한다는 것이다. 즉 $f(\mathbf{X}_s | \boldsymbol{\theta})$ 끼리는 서로 독립이라는 것입니다.

Consensus Monte Carlo Weights

데이터를 나누고 Posterior 까지 나누게 된다면 Posterior Sample 도 각 Shard 마다 다르게 나오게 된다.

$$\theta_{s1}, \dots, \theta_{sG}$$

그럼 이때 Consensus Posterior Sample 의 경우 다음과 같이 나온다.

$$\theta_g = \left(\sum_s w_s \right)^{-1} \sum_s w_s \theta_{sg}$$

우리는 그럼 Weight Vector 를 다음과 같이 설정할 수 있게 된다.

$$w_s = \Sigma_s^{-1}$$

Optimal Weights for Gaussian

예를 들어서 데이터를 2 개의 Shard 으로 나누었는데, Posterior 가 각각 Gaussian 을 따른다고 하자.

$$\pi_1(\boldsymbol{\theta} \mid \mathbf{X}) = N(\boldsymbol{\mu}_1, \Sigma_1), \pi_2(\boldsymbol{\theta} \mid \mathbf{X}) = N(\boldsymbol{\mu}_2, \Sigma_2)$$



그러면 Full Posterior 를 다음과 같이 쓸 수가 있다.

$$\pi(\boldsymbol{\theta} \mid \mathbf{X}) \propto \pi_1(\boldsymbol{\theta} \mid \mathbf{X})\pi_2(\boldsymbol{\theta} \mid \mathbf{X}) \propto N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

이것을 활용해서 진행하면 우리의 Posterior 를 각 Shard 마다 Optimal 한 Weight 를 주면서 구할 수 있게 된다.

마지막으로 각 Shard 를 Batch 으로 바라본다면 이들을 Parallel 하게끔 진행을 하는 것 역시 가능하다.

Consensus Monte Carlo



Model Selection

예를 들어서 모델이 다음과 같이 주어졌다고 가정해보자.

$$\mathcal{M}_1 : E[Y] = \beta_0 + \beta_1 X, \quad \mathcal{M}_2 : E[Y] = \beta_0 + \beta_1 X + \beta_2 X^2$$

두 모델 모두 다음과 같이 $\gamma \in (0, 1)$ 을 통해서 표현이 다음과 같이 가능하다.

$$E[Y] = \beta_0 + \beta_1 X + \gamma \beta_2 X^2$$

그럼 이때 $\gamma \sim \text{Bernoulli}(0.5)$ 의 Prior 으로 둘 수가 있게 된다.

이러한 형태로 모델이 $\mathcal{M}_1, \mathcal{M}_2$ 가 있으며, $P(\gamma = 1 \mid \mathbf{Y}) = P(\mathcal{M}_2 \mid \mathbf{Y})$ 이라고 둘 수가 있다.

Bayes Factor

그럼 2 모델 중에서 하나만 골라주는 Factor 가 있을까?
이것이 바로 Bayes Factor 이다.

$$\text{BF} = \frac{\text{Posterior odds}}{\text{Prior odds}} = \frac{p(\mathcal{M}_2 | \mathbf{Y}) / p(\mathcal{M}_1 | \mathbf{Y})}{p(\mathcal{M}_2) / p(\mathcal{M}_1)} = \frac{p(\mathbf{Y} | \mathcal{M}_2)}{p(\mathbf{Y} | \mathcal{M}_1)}$$

당연히 상황마다 다르겠지만 보통은

- $\text{BF} > 10$: Strong evidence for $\mathcal{M}_2$
- $\text{BF} > 10$: Decisive evidence for $\mathcal{M}_2$

Bayesian Model Averaging (BMA)

반면에 모델끼리의 평균을 내서 진행하는 방법도 있다. 오로지 AIC, BF 와 같은 지표들을 이용해서 모델을 결정하는 방법도 있지만, 이러한 방법들은 선택된 모델이 가장 좋은 것이라는 것에 대한 불확실성을 장담하지는 못한다.

그래서 우리는 다음과 같은 공식을 통해서 각 모델의 Posterior Model Probability (PMP) 를 구합니다.

$$p(\mathcal{M}_k | \mathbf{Y}) = \frac{p(\mathbf{Y} | \mathcal{M}_k) p(\mathcal{M}_k)}{\sum_{k=1}^K p(\mathbf{Y} | \mathcal{M}_k) p(\mathcal{M}_k)}$$

이때 Model Evidence 는 다음과 같이 근사치를 구하는 것이 가능합니다.

$$p(\mathbf{Y} | \mathcal{M}_k) \approx \exp(-0.5\text{BIC}_k)$$

Bayesian Model Averaging (BMA)

이것을 이용해서 다음과 같이 Posterior Average 를 구하는 것이 가능합니다.

- ① Run Independent MCMC for each $\mathcal{M}_k$.
- ② Calculate $p(\mathcal{M}_k | \mathbf{Y})$ using BIC_k .
- ③ For given posterior mean of θ_k , we can obtain $\mathbf{Y}_k^*$.
- ④ Obtain the weighted average of $\mathbf{Y}_k^*$ for $k = 1, 2, \dots, K$.

Spike and Slab Priors

그럼 이것을 실제로 적용시키면 다음과 같이 나옵니다.

- ① Run MCMC Algorithms for Linear Model with Spike and Slab Priors.
- ② Then we will have MCMC Samples of $\beta_i, \lambda_i, \sigma_1^2, \sigma_2^2, \sigma^2$.
- ③ We can estimate posterior inclusion probability for β_i using

$$\hat{P}(\lambda_i = 1) = \frac{1}{T} \sum_{t=1}^T \lambda_i^{(t)}$$

If $\hat{P}(\lambda_i = 1) > 0.5$, we consider X_i an important variable, and include it in the model.